

多模态情感分析：工作汇报


CMU-MOSI / CMU-MOSEI · 2026-09-12 · 1271 次已入库运行 · 154 个实验组 · 17 个模型 · 16 个对比损失 · 12 道自动闸门

三个阶段测出的是同一件事：这个方向上"改进"的报告口径，普遍宽于测量精度本身。

本报告按四张图展开。图 2 是核心——它把「论文声称的效应」「纯噪声」「我们实测的效应」放在同一根坐标轴上，与这套数据能分辨的最小刻度比。

图 1 八年技术演进，重新测了一遍

图 1 八年演进里只有三步显著，而中间那步是「开始微调 BERT」



纵轴为我们复现的测试集 MAE（越低越好）；相邻台阶的判定来自配对 bootstrap（2000 次重采样）。全部数字出自 `outputs/` 下可重算的落盘结果。


复现 14 个模型（2017–2023）后，逐一检验相邻台阶是否真的显著，得到的图景与榜单排序很不一样：

- 2017–2019 的三个模型之间没有显著差异。LMF 的 19 倍参数压缩确实不花钱，MFN 的跨时间记忆也确实买不到东西。
- 只有三步显著：TFN→MulT、MulT→MISA、MISA→Self-MM。
- 2021 年之后进入平台期。CENET(2022) 在 MAE 上还显著更差，TETFN(2023) 与 Self-MM(2021) 统计不可区分。

红线是这张图的关键。我们加了一个对照组：只微调 BERT、完全不用音视频，得到 0.8018——显著优于 MuT 及此前全部冻结特征的模型，与 MISA 在 Corr 和 Acc-2 上统计不可区分。

把两件事合起来读：真正显著的三步里，中间那步恰好是"开始微调 BERT"。这条八年演进可归结为：冻结特征时代内部无显著进步 → 换成微调文本编码器带来唯一一次真实跃升 → 此后进入平台期。融合结构的设计贡献，远小于编码器换代。

图 2 效应量与这台仪器的刻度（核心图）



橙=论文自己声称的效应；红=与方法无关的纯噪声；黑=我们实测的效应。绿线为最小可检测效应（MDE，80% 检出力）：MOSI 在 n=20 下是 0.013，MOSEI 是 0.0039。

这张图要说的是：横轴上这些量，有一大半落在绿线左边——也就是这套数据根本分辨不出来。

读法	含义
红条落在绿线右边	纯噪声比分辨极限还大。MOSI 上 LF-LSTM 换个 seed 重跑，MAE 波动 0.0387
橙条 0.038	同一个已发表的 MMIM，在两篇论文里被报成 0.700 与 0.738（一个 unaligned、一个 aligned，两边都没错）——跨论文分歧是我们分辨极限的三倍
橙条 0.056	HyCon 自己的消融声称对比学习值这么多。若在我们的协议下成立，不可能测不出来
黑条最长者 0.0174	我们第 2 阶段全部对比损失效应的上界——整批候选都挤在绿线附近

这解释了第 2 阶段为什么反复测不出东西：不是方法不行，是那个效应量本来就在噪声以下。而这不是事后辩解——MDE 只取决于样本量和标准差，事前就能算出来。


第 2 阶段：负面结论为什么可信

老师最该追问的是"是不是没调好"。三条正面回答：

- 1. 测试槽位事先被证明灵敏。MMIM 自带的对比项在同一槽位让验证 MAE 动 $|d|=1.39$ ，而那个模型经权重复制的数值等价测试，与参照实现 **逐比特一致**（最大绝对差 $0.000e+00$ ）。灵敏度是测量值，不是假设。
- 2. 每个"没检出"都附最小可检测效应（图 2 的绿线）。
- 3. 三条假线索被预注册的复现批次抓住：「组合优于纯 L1」（ $p=0.045$ ）在第三批 seed 上**符号翻转**；`dcl` 的优势缩了一半；我们自己设计的 `label_dcl`，机制增量归零（ $+0.0044 \rightarrow +0.0004$ ，Corr 符号翻转）。

损失线上最后站得住的只有：一个文献已有的去耦合对比项（`dcl`）让 MMIM 在 MOSEI 上改进约 0.007 MAE（相对 1.3%）——那不是我们的设计。产出形式仍然完整：设计了损失、做了单一机制的消融、三批独立 seed、判据全部先立后测。结论是负面的，而这个负面结论本身是可信的产出。

图 3 八篇对标：报告值的高低与它可被检验的程度无关



各篇论文自报的 MOSI MAE，全部从其 PDF 抄录并注明表号（见 `docs/benchmark_contrastive.md`），无一凭记忆填写。

老师要求复现 8 篇含对比学习的论文做对标，篇目由我们自定。选取标准：方法里确有对比学习项、在 MOSI/MOSEI 上报回归指标、覆盖 2021-2024，并优先有公开代码——**能跑通的才叫复现**。


档	篇数	论文
A 在我们 sha256 校验过的特征上跑通	3	MMIM、ConFEDE、HSCL
B	0	—
C 只能引用论文报告值	5	UniMSE、HyCon、ConKI、CMSBERT-CLR、MMCL

这个计数本身是结论的一部分。八篇里 四篇从未公开代码；第五篇 UniMSE 公开了，但兼容层全部做完、数据按我们的 划分加载成功、T5 载入、optimizer 建好之后，**死在第一个 batch**——它发布版 读原始数据的那条路径与自己的 `collate_fn` 不一致，作者实际跑的预处理文件 不在仓库里，而那些文件把论文的"统一标签空间"烘在里面，**我们的特征无从替换**。而 UniMSE 恰好是全表报告值第二好的那篇。

A 档里靠读代码和跑受控对照拿到的三条：

- **ConFEDE 已复现**：MAE 0.7379 ± 0.0050 对论文 0.742，Corr 0.7805 对 0.784，**都在 0.004 以内**；Acc-7 反而高 2.6 个点。但它报的 seed 方差不能按字面读——`main.py` 没有 seed 循环，三个编码器只预训练一次，五个融合 seed 共用同一套权重。
- **HSCL 的模型选择读了测试集**：上报的那一轮必须同时"验证变好"且"测试变好"。
- **HSCL 固定 seed 也不可复现**（见图 4 的讨论）。

图 4 重跑一次的噪声，与论文声称的改进同量级



测试集 MAE 的 seed 间标准差，全部由我们自己的落盘运行重算得到。浅色带为文献中"改进"常见的幅度区间。

这张图解释了为什么我们坚持多 seed、以及为什么要转向 MOSEI：

- **MOSI 上换个 seed 就有 0.019–0.039 的波动**，横跨整个"改进"区间。在这样的噪声上报单次运行的数字，等于报一个量级不明的数。
- **MOSEI 小一个量级**（LF-LSTM 0.0049）。这直接推翻了"大数据集跑不起"的担忧：MOSEI 上 5 个 seed 的分辨力已优于 MOSI 上 20 个，而单 seed 只慢 3.1 倍。
- **HSCL 更极端**：同一份发布版代码、同一个 seed、连跑两次，20 轮里 **0 轮逐位相同**，上报 MAE 差 0.0079——比图 3 里好几个"改进"还大（MMCL 相对 MMIM 是 0.005）。原因是它只设了 `cudnn.deterministic`，那只管 cuDNN 卷积，管不到 BERT 反向里的原子加。

对照我们自己的做法：`check_repro.py` 是 12 道闸门之一，专门问"同一台机器连跑两次是否逐比特一致"；LF-LSTM 默认路径的预测哈希 `172967c7dced83b2` 贯穿多次重构未变。这不是讲究——没有这道闸门，"改动 A 带来了 0.005 的提升"这句话根本无法成立，而这整个阶段读到的就是这句话被反复说出来。

正在进行：QKV 门控加权

老师提的第三件事。改的位置是 ALMT 的 `_HyperLayer`：文本做 query、音频与视觉各做 key/value，两路注意力结果以固定权重 1 相加才过输出投影——从不相互加权。门控从形成 query 的那份文本读出两个权重去加权这两路。

`alpha=0` 逐比特等于发布版 ALMT，而这是测出来的。把门控参数加上 10 倍标准差的随机扰动后：

检查	输出最大绝对差	要求
<code>alpha=0</code> ，门控参数被大幅扰动	0.000e+00	须为 0（门控确实够不到输出）
<code>alpha=0.5</code>	2.29e-03	须非 0（门控确实接上了）

两头都测是必要的：只测前者，"等价"也可能是因为门控压根没接上——那样消融两臂之差恒为零，会以"无效应"的面目通过，而其实什么都没测。这道检查已进 `check_all.sh`。

判据在运行前已定稿并推送：seeds 200–219（n=20 每臂）、验证集 MAE 与 Corr、Welch 单侧 + BH 校正、效应必须达到 MDE 0.0114 否则记「未检出」、不做 alpha 扫描（图 2 已经说明，在检出力不足处多试取值只会制造假线索）。

为什么这值得测、而不是又一个微弱杠杆：第 1 阶段的模态消融显示 MOSI 上音视频几乎不携带信息，而 ALMT 恰好把这两路无条件等权相加。门控若有用，方向应当是学会压低无信息的那一路——一个有机制、可证伪的预测。

全部数字可从仓库重算：`scripts/verify_runs.py` 从落盘预测重算指标，`scripts/reproduce_all.sh` 重跑全部实验，`scripts/check_all.sh` 跑 12 道闸门，`scripts/make_report_figures.py` 重画本报告四张图。文档：`docs/storyline.md`（逐模型复盘）、`docs/experiments.md`（全部数字）、`docs/investigations.md`（排查记录，含每一次自我更正）、`docs/decisions.md`（判据与理由）、`docs/benchmark_contrastive.md`（8 篇名单与分档）。